

EasyHap

区域单倍型分析与可视化软件

V1.0 使用说明书

软件开发：Guangqi He

文档版本：V1.0

编制日期：2026 年 6 月

文档说明

本说明书用于介绍 EasyHap 区域单倍型分析与可视化软件 V1.0 的运行环境、安装方法、输入文件格式、图形界面操作、命令行参数、分析模式、结果文件及常见问题。文档适用于软件著作权登记、软件交付、用户培训和日常分析使用。

EasyHap 以经过相位处理的 VCF、VCF.GZ 或 BCF 文件为主要输入，面向真菌、植物和动物群体重测序数据中的区域单倍型分析。软件能够自动识别单倍体、二倍体及多倍体基因型，并提供近交/自交群体和杂交/异交群体两类分析策略。

项目	内容
软件名称	EasyHap 区域单倍型分析与可视化软件
软件简称	EasyHap
版本号	V1.0
主要运行平台	Windows 10/11 64 位；主流 x86-64 Linux 系统
开发语言	Python 3
主要输入	相位 VCF/VCF.GZ/BCF、样本分组文件，可选表型、区域及 GFF3/GTF 文件
主要输出	单倍型汇总表、群体统计表、FASTA/NEXUS/PHYLIP 序列及 PDF/SVG/PNG 图形

目录

- 1 软件概述
- 2 运行环境与安装
- 3 输入文件说明
- 4 输入数据预处理
- 5 Windows 图形界面使用方法
- 6 Linux 命令行使用方法
- 7 分析模式与参数选择
- 8 典型分析示例
- 9 输出文件说明
- 10 图形结果说明
- 11 推荐分析流程

12 常见问题与处理方法

附录 A 参数速查表

附录 B 输出文件速查表

1 软件概述

1.1 软件简介

EasyHap 是一款面向群体重测序项目的跨平台区域单倍型分析与可视化软件。软件以相位 VCF 数据为基础，在指定基因、候选区间或批量基因组区域内完成变异编码、单倍型重构、群体比较、序列相似性聚类、表型关联、序列导出和出版级绘图。

软件支持 SNP、InDel、多等位位点，以及以等位基因形式记录的 PAV 和结构变异。对于不同倍性和繁殖体系的数据，EasyHap 能够根据基因型字段自动识别样本倍性，并由用户选择与群体结构相匹配的分析模式。

1.2 适用范围

- 候选基因或候选区间的单倍型鉴定与频率统计；
- GWAS 候选区域的单倍型精细解析；
- 驯化、改良或选择清除区段的群体单倍型比较；
- 优异单倍型筛选及其与农艺性状、表型指标的关联分析；
- 真菌、植物及动物群体中的单倍体、二倍体和多倍体区域单倍型分析；
- 单倍型序列导出、系统发育分析及单倍型网络分析前的数据准备。

1.3 主要功能

功能	说明
变异处理	对 SNP、InDel、多等位位点及 PAV/SV 进行统一解析和紧凑编码。
倍性识别	从 GT 字段自动识别单倍体、二倍体和多倍体基因型。
单倍型重构	支持近交/自交模式和杂交/异交模式，分别生成基因型级或染色体拷贝级单倍型。
群体比较	统计单倍型或聚类类别在不同群体中的数量、频率与组成。
变异筛选	可对两个指定群体进行 Fisher 精，支持 BH 多重检验校正。

功能	说明
相似性聚类	按标准化 Hamming 距离将相近单倍型划分为聚类类别。
表型关联	对连续型性状进行 Kruskal-Wallis 总体检验和 Mann-Whitney U 两两比较。
多格式输出	输出 TSV、FASTA、NEXUS、PHYLIP 及 PDF/SVG/PNG 图形。
双界面运行	提供 Linux 命令程序和 Windows 图形用户界面。

1.4 软件工作流程

EasyHap 的工作流程由数据输入、变异处理、单倍型识别、单倍型汇总、群体比较与筛选、表型关联、多格式输出及可视化组成。用户可仅提供必需的 VCF 和样本分组文件，也可增加基因注释和表型文件以生成更完整的分析结果。




图 1 EasyHap 主要分析流程及输出类型

2 运行环境与安装

2.1 硬件系要求

项目	建议配置
处理器	x86-64 双核及以上处理器，建议 CPU 主频 2.0 GHz 以上
内存	最低 8 GB；大规模 VCF 数据建议 16 GB 或以上
存储空间	软件安装空间约 1 GB 以内；另需预留输入数据和结果文件空间
Windows 平台	Windows 10/11 64 位
Linux 平台	Ubuntu、CentOS 及其他主流 x86-64 Linux 系统

2.2 Windows 版本安装与启动

Windows 发布包提供独立可执行程序，正常情况下无需用户单独安装 Python 环境。

1. 下载并解压 EasyHap-1.0.zip 软件包。
2. 打开解压后的 Windows 目录。
3. 双击 EasyHap.exe 启动软件。
4. 首次使用时，可利用软件包提供的 examples 示例文件测试完整流程。

若 Windows 安全中心提示来自未知发布者，可在确认软件来源可靠后选择“仍要运行”。建议将软件解压到不含特殊符号的本地目录中，避免直接在压缩包内运行。

2.3 Linux 版本依赖环境

Linux 命令行版本需要 Python 3，并依赖以下核心 Python 程序库：

程序库	最低版本
pandas	1.5
numpy	1.23
matplotlib	3.6
scipy	1.10
cyvcf2	0.30

2.4 在已有 Python 环境中安装

```
unzip EasyHap-1.0.zip
cd EasyHap-1.0/Linux
python3 -m pip install "pandas>=1.5" "numpy>=1.23" "matplotlib>=3.6" "scipy>=1.10" "cyvcf2>=0.30"
python3 -m pip install -e .
easyhap --version
```

2.5 在 Conda 环境中安装

```
conda create -n easyhap python=3.10 -y
conda activate easyhap
python -m pip install "pandas>=1.5" "numpy>=1.23" "matplotlib>=3.6" "scipy>=1.10" "cyvcf2>=0.30"
unzip EasyHap-1.0.zip
cd EasyHap-1.0/Linux
python -m pip install -e .
easyhap --version
```

2.6 在 Linux 中启动图形界面

如果 Linux 系统已安装并配置 Tkinter，可在 EasyHap 源代码目录中运行以下命令启动图形界面：

```
python easyhap_gui.py
```

Linux 服务器通常不配置图形桌面环境，建议在服务器上优先使用 easyhap 命令行程序。

3 输入文件说明

EasyHap 至少需要一个相位 VCF/VCF.GZ/BCF 文件和一个样本分组文件。表型文件、批量区域文件及 GFF3/GTF 基因注释文件均为可选输入。所有文本表格建议使用 UTF-8 编码和制表符分隔。

3.1 相位 VCF、VCF.GZ 或 BCF 文件（必需）

输入文件必须包含相位基因型，等位基因之间应使用竖线“|”分隔。例如，单倍体可表示为 0 或 1，二倍体可表示为 0|1 或 1|0，多倍体可表示为 0|1|1|0。

```
0|1
1|0
0|1|1|0
```

EasyHap 从 GT 字段自动推断倍性，用户不需要另外指定单倍体、二倍体或多倍体。对于 InDel 和 PAV/SV 的序列级分析，推荐使用包含明确 REF 和 ALT 序列的变异记录。仅使用<PAV>等符号等位基因时，无法完全重建插入序列，因此输出以状态编码为主。

大规模数据推荐使用 bgzip 压缩并建立 tabix 或 CSI 索引。索引文件可显著提高指定区域的访问速度。

```
##fileformat=VCFv4.2
##source=EasyHap-1.0-demo
##contig=<ID=ChrDemo,length=5000>
##FORMAT=<ID=GT,Number=1,Type=String,Description="Phased genotype">
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT C001 C002 C003 C004
ChrDemo 1100 demoV1 A G,T,C . PASS . GT 0|1 0|1 0|1 0|1
ChrDemo 1250 demoV2 C G,T . PASS . GT 0|0 0|0 0|0 0|0
```

3.2 样本分组文件（必需）

样本分组文件必须使用制表符分隔，且不包含表头。第一列为样本名称，第二列为群体或试验分组名称。样本名称必须与 VCF 表头中的样本名称完全一致。

```
C001 Cultivar
C002 Cultivar
C003 Landrace
```

3.3 表型文件（可选）

表型文件必须使用制表符分隔并包含表头。第一列为样本或材料名称，后续列为数值型性状。第一列样本名称应与 VCF 中的样本一致。命令行模式可通过--trait-cols 选择一个或多个性状。

Accession	Plant_height	Seed_weight
C001	9.2	98.0
C002	9.6	100.0
C003	10.0	102.0
C004	10.4	104.0

3.4 批量区域文件（可选）

批量区域文件用于同时分析多个基因组区间。文件必须使用制表符分隔且不包含表头，三列依次为染色体或序列名称、起始坐标和终止坐标。

ChrDemo	900	2900
ChrDemo	3000	4200

单个区间使用--region 参数，格式为 chr:start-end；多个区间使用--region-file 参数。两者为替代关系，通常不应同时指定。

3.5 GFF3 或 GTF 基因注释文件（可选）

GFF3 或 GTF 文件用于在单倍型图上同时绘制基因结构。软件可识别 gene、mRNA/transcript、exon、CDS 及 UTR 等常见功能类型。

```
##gff-version 3
ChrDemo EasyHapgene 1000 2800 . + . ID=DemoGene1;Name=DemoGene1
ChrDemo EasyHapmRNA 1000 2800 . + . ID=DemoGene1.1;Parent=DemoGene1
ChrDemo EasyHapexon 1000 1350 . + . ID=exon1;Parent=DemoGene1.1
ChrDemo EasyHapCDS 1100 1350 . + 0 ID=cds1;Parent=DemoGene1.1
```

3.6 文件一致性要求

- VCF、区域参数或区域文件、GFF3/GTF 文件中的染色体或 contig 名称必须一致；
- 样本分组文件和表型文件中的样本名称必须与 VCF 表头完全一致；
- 输入表格必须使用真实制表符，不应使用连续空格代替；
- 样本分组文件和区域文件不得包含表头；表型文件必须包含表头；
- 使用多个 VCF 进行合并前，应确保样本集合和样本顺序一致。

4 输入数据预处理

下列命令为 VCF 预处理示例。实际分析时应根据物种、测序深度、样本数量和变异检测流程调整文件名、阈值、参考基因组及计算资源。EasyHap 本身不会替代上游变异质控和相位处理。

4.1 按缺失率和次要等位基因频率筛选

```
vcftools --gzvcf sample.snp.pass.vcf.gz --max-missing 0.8 --maf 0.01 --recode --stdout | bgzip -c >
sample.snp.popfilter.vcf.gz
bcftools index -t sample.snp.popfilter.vcf.gz
```

--max-missing 0.8 表示位点至少在 80% 的样本中具有有效基因型；--maf 0.01 表示保留次要等位基因频率不低于 0.01 的位点。

4.2 合并 SNP、InDel 和 PAV/SV 文件

合并前，各输入文件应包含相同样本并保持相同样本顺序。

```
bcftools concat -a sample.snp.popfilter.vcf.gz sample.indel.popfilter.vcf.gz sample.pav.popfilter.vcf.gz -Ou | \
bcftools sort -Oz -o sample.snp_indel_pav.vcf.gz
bcftools index -t sample.snp_indel_pav.vcf.gz
```

4.3 仅保留双等位位点（可选）

EasyHap 支持多等位位点，因此双等位筛选不是必需步骤。若研究设计要求仅分析双等位变异，可运行：

```
bcftools view -m2 -M2 -Oz -o sample.snp_indel_pav.biallelic.vcf.gz sample.snp_indel_pav.vcf.gz
bcftools index -t sample.snp_indel_pav.biallelic.vcf.gz
```

4.4 二倍基因型相位

对于二倍体数据，可使用适当的相位软件生成以“|”分隔的相位基因型。以下为 Beagle 示例：

```
java -jar beagle.27Feb25.75f.jar gt=sample.snp_indel_pav.vcf.gz out=sample.snp_indel_pav_beagle seed=123
nthreads=48
bcftools index -t sample.snp_indel_pav_beagle.vcf.gz
```


多倍体数据应选用适合目标物种、倍性水平、测序设计和变异类型的相位方法。完成相位后再运行 EasyHap。

5 Windows 图形界面使用方法

5.1 启动界面

双击 EasyHap.exe 后进入主界面。界面包含文件选择区、区域设置区、分析参数区、运行按钮和日志输出区。标记为 Requirement 的 VCF、Sample group 和 Output directory 为必填项。




图 2 EasyHap V1.0 Windows 图形用户界面

5.2 界面字段说明

界面项目	功能说明
VCF	选择相位 VCF、VCF.GZ 或 BCF 文件，必填。
Sample group	选择样本分组文件，必填。
Trait table	选择表型数据表，可选。
GFF/GTF	选择基因注释文件，可选。

界面项目	功能说明
Output directory	选择结果输出目录，必填。
Region	输入单个区间，例如 Chr10:1-500。
or region file	选择批量区域文件，与 Region 二选一。
Mode	选择 inbred 或 hybrid 分析模式。
Hetero policy	近交模式下杂合位点的编码方式：slash、iupac 或 missing。
Plot	勾选后生成图形结果。
Format	指定图形格式，可输入 pdf、svg、png 或逗号分隔的多种格式。
Plot level	选择 hap 原始倍型或 cluster 聚类层级。
Plot min count	图中显示类别的最小样本数，仅影响绘图。
Fisher groups	输入两个比较群体，如 Cultivar, Landrace。
alpha	Fisher 筛选阈值。
adjust	选择 none 或 bh 多重检验校正。
Run	启动分析。
日志区	显示运行状态、完成区间数、输出前缀及错误信息。

5.3 基本操作步骤

1. 单击 VCF 右侧的 Browse 按钮，选择相位 VCF 文件。
2. 选择 Sample group 样本分组文件。
3. 根据需要选择 Trait table 和 GFF/GTF 文件。
4. 选择 Output directory 结果目录。
5. 在 Region 中输入单个区间，或选择 region file 进行批量分析。
6. 根据群体结构选择 Mode，并设置杂合位点编码策略。
7. 需要绘图时勾选 Plot，并设置图形格式、绘图层级和最小类别数量。
8. 需要群体位点筛选时填写 Fisher groups、alpha 和 adjust。
9. 单击 Run 启动分析，在下方日志区查看运行状态。

5.4 图形界面使用注意事项

- Region 和 region file 至少提供一项；

- Fisher groups 必须恰好填写两个群体名称，并使用英文逗号分隔；
- alpha 必须为数字；
- Plot min count 必须为大于等于 1 的整数；
- 界面在后台线程中运行分析，运行期间不建议重复单击 Run；
- 结果文件保存在所选输出目录中，每个区域具有独立的文件名前缀。

6 Linux 命令行使用方法

6.1 看主助信息

```
easyhap -h
```

EasyHap 包含 prepare 和 analyze 两个子命令：

- prepare：将原始 REF 和 ALT 等位基因转换为适合后续分析和绘图的紧凑状态编码。
- analyze：执行完整分析，包括等位基因编码、单倍型重构、筛选、聚类、序列导出以及可选绘图。

等位基因准备过程已经集成到 analyze 命令中，多数用户无需单独运行 prepare。

6.2 prepare 命令

```
easyhap prepare \  
--vcf sample.phased.vcf.gz \  
--region Chr10:1-500 \  
--outdir prepare_out
```

prepare 命令适用于只希望查看变异编码表和样本基因型编码表的场景。可使用--region-file 替代--region 进行多个区域的批量转换。

6.3 analyze 命令

```
easyhap analyze -h
```

必需参数为--vcf、--group 和--outdir，同时必须通过--region 或--region-file 至少提供一个基因组区域。

参数	说明
--vcf	相位 VCF、VCF.GZ 或 BCF 文件。
--group	无表、制表符分隔的本分文件。
--region	单个区间，例如 Chr10:1-500。
--region-file	无表头、制表符分隔的批量区域文件。
--outdir	出目。

参数	说明
--mode {inbred,hybrid}	单倍型重构策略，默认 inbred。
--hetero-policy {slash,iupac,missing}	inbred 模式下合位点方式。
--traits	可的制表符分隔表型文件。
--trait-cols	需要制和的性列，多列用英文逗分隔。
--fisher-groups	用于 Fisher 筛选的两个群体，例如 Cultivar, Landrace。
--fisher-alpha	Fisher 筛选的原始或校正 P。
--fisher-adjust {none,bh}	Fisher 筛选的多重检验校正方法。
--cluster-threshold	单倍型聚类的标准化 Hamming 距离阈值，默认 0.15。
--vcf-backend {auto,cyvcf2,pysam,plain}	VCF 读取后端，默认 auto。
--no-processed	不出理后的表和基因型表。
--plot	生成形果。
--gff	用于基因结构-单倍型联合图的 GFF3/GTF 文件。
--plot-format	图形格式，支持 pdf、svg 和 png，多个格式用逗号分隔。
--plot-hap-level {hap,cluster}	按原始倍型或聚。
--plot-min-count	图中显示类别的最小样本数，默认 1。

6.4 端出信息

分析完成后，程序会报告完成的区域数量，并列出的每个区域的 HapSummary、HapGroup 和输出前缀。例如：

```
Finished 1 region(s).
[ChrDemo:900-2900]
HapSummary: demo_diploid/ChrDemo_900_2900.HapSummary.tsv
HapGroup:  demo_diploid/ChrDemo_900_2900.HapGroup.tsv
Prefix:  demo_diploid/ChrDemo_900_2900
```

7 分析模式与参数选择

7.1 hybrid 模式

```
--mode hybrid
```

hybrid 模式重构相位染色体拷贝级单倍型。该模式适用于杂合度较高的二倍体样本、杂交或异交群体，以及已经相位的多倍体基因型。每个相位拷贝单独分析，从而保留拷贝层面的等位基因排列。

7.2 inbred 模式

```
--mode inbred
```

inbred 模式构建基因型级单倍型谱，适用于近交系、自交系或多数位点预期为纯合的群体。该模式避免在以纯合基因型为主的群体中对多拷贝相位组合进行不必要的强调。

7.3 合位点策略

参数值	含义
slash	保留显式组合形式，如 A/G；适合需要直接观察杂合组成的分析。
iupac	在条件允许时使用 IUPAC 简并碱基编码，如 A/G 编码为 R。
missing	将杂合位点编码为缺失值 N；适合不希望杂合位点参与单倍型区分的场景。

分析模式应根据群体繁殖体系、样本杂合程度和生物学解释选择，而不能只依据名义倍性。例如，二倍体近交材料通常更适合 inbred 模式，而二倍体杂交群体通常更适合 hybrid 模式。

7.4 Fisher 筛选

指定--fisher-groups、--fisher-alpha 和--fisher-adjust 后，软件在两个群体之间对每个位点进行 Fisher 精确检验，并仅保留达到阈值的变异。--fisher-adjust bh 使用 Benjamini-Hochberg 方法控制多重检验。该筛选会改变用于后续单倍型重构的位点集合。

7.5 倍型相似性聚

--cluster-threshold 控制标准化 Hamming 距离阈值。阈值越大，允许差异更多的单倍型连接到同一聚类类别；阈值越小，聚类越严格。--plot-hap-level cluster 仅改变绘图和类别展示层级，不会删除原始单倍型结果。

7.6 最小显示数量

--plot-min-count 仅控制图中显示的单倍型或聚类类别，不参与 Fisher 位点筛选，也不会删除表格中的原始分析结果。该参数适合在单倍型类别很多时减少低频类别造成的视觉拥挤。

8 典型分析示例

8.1 示例一：hybrid 模式分析

该示例对 ChrDemo:900-2900 区域进行染色体拷贝级单倍型分析，不进行 Fisher 筛选，并绘制原始单倍型层级的图形。

```
easyhap analyze \
--vcf ./examples/demo_diploid_multiallelic.vcf \
--group ./examples/sample_group.tsv \
--gff ./examples/demo.gff3 \
--region ChrDemo:900-2900 \
--mode hybrid \
--traits ./examples/traits.tsv \
--trait-cols Plant_height,Seed_weight \
--vcf-backend plain \
--plot \
--plot-format pdf \
--outdir demo_diploid
```

Prefix: demo_diploid/ChrDemo_900_2900

Example graphical output:

Hybrid mode, hap-level plot and no Fisher filtering




图 3 hybrid 模式、原始单倍型层级且不进行 Fisher 的示例果

8.2 示例二：inbred 模式、群体筛选与聚类绘图

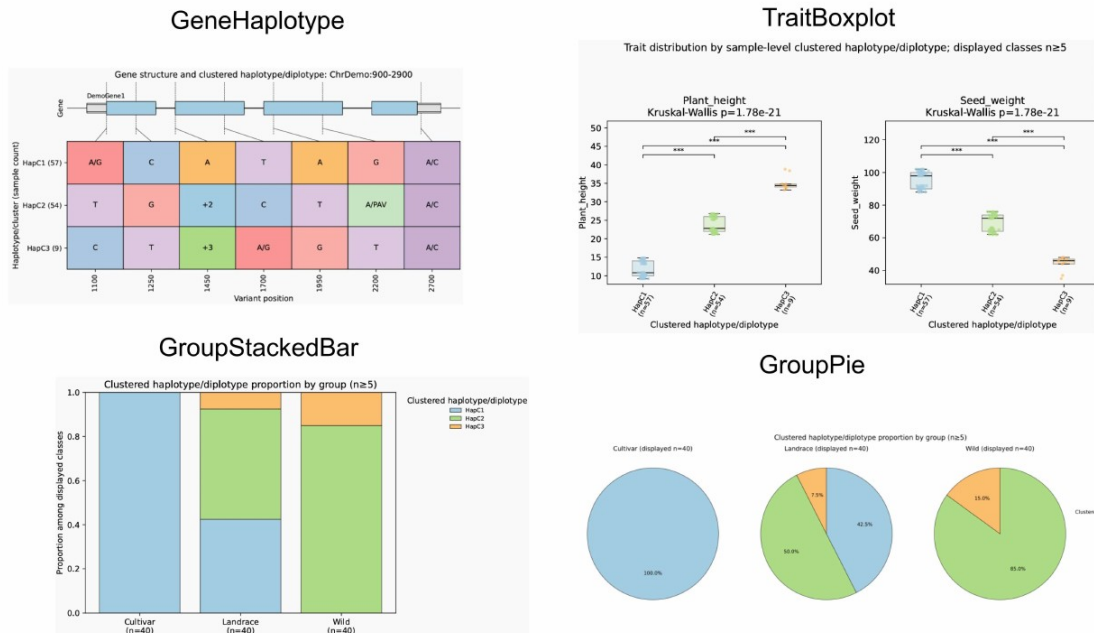
该示例使用 Cultivar 与 Landrace 两个群体进行 Fisher 检验，采用 BH 校正并保留校正 P 值不大于 0.05 的位点；按聚类类别绘图，仅显示样本数不少于 5 的类别。

```
easyhap analyze \
--vcf ./examples/demo_diploid_multiallelic.vcf \
--group ./examples/sample_group.tsv \
--gff ./examples/demo.gff3 \
--region ChrDemo:900-2900 \
--mode inbred \
--hetero-policy slash \
--fisher-groups Cultivar,Landrace \
--fisher-alpha 0.05 \
--fisher-adjust bh \
--traits ./examples/traits.tsv \
--trait-cols Plant_height,Seed_weight \
--vcf-backend plain \
--plot \
--plot-format pdf \
--plot-hap-level cluster \
--cluster-threshold 0.5 \
--plot-min-count 5 \
--outdir demo_diploid_2
```

```
--plot-min-count 5 \
--outdir demo_diploid_2
```

Example graphical output:

Inbred mode, cluster-level plot, Fisher filtering (BH adjusted $P < 0.05$) and hap count



This example differs from the hybrid-mode analysis in several important ways:

图 4 inbred 模式、Fisher 筛选、聚类层级及最小显示数量限制的示例结果

与示例一相比，本示例的主要差异是：Fisher 筛选改变了变异集合；相似性聚类减少了重复类别；最小数量参数只影响图形显示；inbred 模式采用基因型级类别。

8.3 多区域批量分析

使用--region-file 替代--region 即可批量分析多个区间。每个区间根据染色体、起始坐标和终止坐标生成独立输出前缀。

```
easyhap analyze \
--vcf sample.phased.vcf.gz \
--group sample_group.tsv \
--region-file regions.tsv \
--mode inbred \
--plot \
--plot-format pdf,png \
--outdir easyhap_batch
```

9 输出文件说明

对于 ChrDemo:900-2900 区域，EasyHap 使用 ChrDemo_900_2900 作为文件前缀。输出文件由所选参数决定。未启用绘图时不生成图形文件；未提供表型文件或 GFF3/GTF 文件时，相应统计表或基因结构图不会生成。

输出文件	内容说明
*.AlleleStateMap.tsv	原始等位基因/基因型状态与紧凑编码状态的映射表。
*.ProcessedVariants.tsv	包含准化等位基因的信息表。
*.SampleGenotypeTokens.tsv	所有本在各位点的基因型。
*.HapSummary.tsv	原始单倍型、聚类编号、各位点状态、材料名称和数量。
*.HapGroup.tsv	样本级单倍型、聚类、群体和可选表型信息。
*.Haplotype.fa	去冗余单倍型序列的 FASTA 文件。
*.Haplotype_sample.fa	样本级或样本拷贝级单倍型 FASTA 文件。
*.Haplotype.nex	NEXUS 格式的倍型比文件。
*.Haplotype.phy	PHYLIP 格式的单倍型比对文件。
*.TraitSignificance.tsv	所选性状的总体及两两统计检验结果。
*.GeneHaplotype.pdf	基因结构与单倍型/变异联合图。
*.HaplotypeHeatmap.pdf	单倍型状态热图。
*.GroupPie.pdf	各群体中单倍型或聚类类别的组成饼图。
*.GroupStackedBar.pdf	不同群体的单倍型频率堆叠柱形图。
*.TraitBoxplot.pdf	不同单倍型或聚类类别的性状分布箱线图。

9.1 等位状态映射表

CHROM	POS	OriginalToken		EncodedState
ChrDemo	1100	A	A	
ChrDemo	1100	A/G	N	
ChrDemo	1100	T	T	

该文件记录原始序列或基因型状态如何转换为用于汇总、序列比对和绘图的单字符编码。

9.2 处理后的变异表

CHROM	POS	ID	REF	ALT	AlleleTokens
ChrDemo	1100	demoV1	A	G,T,C	A,G,T,C
ChrDemo	1250	demoV2	C	G,T	C,G,T
ChrDemo	1450	demoV3	A	ATG,ATTG	A,+2,+3

序列长度变化可编码为+2、+3、-1等紧凑状态，从而避免在汇总表和图中重复显示长序列。

9.3 样本基因型编码表

CHROM	POS	ID	C001	C002
ChrDemo	1100	demoV1	A/G	A/G
ChrDemo	1250	demoV2	C/C	C/C
ChrDemo	1450	demoV3	A/A	A/A

9.4 单倍型汇总表

Hap	ClusterID	1100	1250	1450	1700	1950	2200	2700	Accession	Number
Hap001	HapC1	A	C	A	T	A	G	A	C005;C006;C007;C008	4
Hap002	HapC2	T	G	+2	C	T	PAV	A	L029;L030;L031;L032	4

表中每一行为一个单倍型，ClusterID为相似性聚类编号，后续列为各变异位点状态，Accession记录材料列表，Number记录材料数量。

9.5 单倍型-群体表

Hap	ClusterID	Accession	Type	Plant_height	Seed_weight
Hap006	HapC1	C001	Cultivar 9.2	98.0	
Hap006	HapC1	C002	Cultivar 9.6	100.0	
Hap006	HapC1	C003	Cultivar 10.0	102.0	

该表将每个样本与单倍型、聚类类别、群体及可选表型信息关联，是后续群体统计和表型解释的重要结果。

9.6 样本拷贝 FASTA

```
>C001|Hap006  
NCATAGG  
>C002|Hap006  
NCATAGG  
>C003|Hap006  
NCATAGG
```

FASTA、NEXUS 和 PHYLIP 文件可用于后续系统发育树、单倍型网络或其他序列比较分析。

9.7 性状显著性表

对于每个选择的性状，软件可报告跨全部显示类别的 Kruskal-Wallis 检验、两两 Mann-Whitney U 检验、BH 校正 P 值及图中使用的显著性符号。

10 图形结果说明

使用--plot 参数或在图形界面中勾选 Plot 后生成图形。图形可输出为 PDF、SVG 和 PNG。可用的图形类型取决于用户提供的输入文件和参数。

10.1 单倍型热图

单倍型热图按行显示单倍型或聚类类别，按列显示变异位点。每个单元格中的字母或紧凑状态代表该单倍型在相应位点的等位基因。行名后的数字表示该类别包含的样本数。

10.2 基因结构-单倍型联合图

提供 GFF3/GTF 文件后，软件在热图上方绘制基因结构，包括外显子、CDS 和 UTR，并用连线对应变异位点。该图适合展示变异在基因结构中的位置及不同单倍型的等位状态。

10.3 群体堆叠柱形图

堆叠柱形图展示各群体中不同单倍型或聚类类别的相对比例。使用 cluster 层级时，图例和柱形颜色表示聚类类别；使用 hap 层级时表示原始单倍型或基因型组合。

10.4 群体组成饼图

饼图分别显示每个群体的单倍型组成，可直观比较不同群体中的优势类别、共享类别和群体特异类别。

10.5 性状箱线图

提供表型文件后，软件绘制各单倍型或聚类类别的性状分布箱线图，并叠加样本散点。图题中可显示 Kruskal-Wallis 总体 P 值，显著的两两比较以星号标注。

符号	含义
ns	$P > 0.05$
*	$P \leq 0.05$
**	$P \leq 0.01$
***	$P \leq 0.001$

10.6 绘图参数示例

```
--gff annotation.gff3
--traits traits.tsv
--trait-cols Plant_height,Seed_weight
--plot-format pdf,svg,png
--plot-hap-level cluster
--plot-min-count 5
```

11 推荐分析流程

在正式群体数据中使用 EasyHap 时，建议按以下顺序开展分析：

流程	操作要点
步骤 1：整理上游变异数据	完成变异检测、标准化、质量控制和相位，确保 VCF 中的样本及 GT 字段正确。
步骤 2：建立样本分组文件	按究本分栽培、地方品、野生材料或其他试验组。
步骤 3：确定分析区域	根据候选基因、GWAS 峰、选择清除区间或其他生物学问题确定单个或批量区域。
步骤 4：选择分析模式	近交/自交群体优先选择 inbred；杂交/异交群体或需要拷贝级相位解释时选择 hybrid。
步骤 5：运行基础分析	先不启用 Fisher 筛选，检查位点数量、单倍型数量和主要输出是否符合预期。
步骤 6：进行群体筛选或聚类	根据研究目的启用 Fisher 筛选，并设置合理的聚类距离阈值。
步骤 7：加入表型和基因注释	提供表型表和 GFF3/GTF 文件，生成性状关联和基因结构联合图。

流程	操作要点
步骤 8：核查和解释结果	结合样本数量、群体结构、表型分布及原始变异记录解释优势单倍型。
步骤 9：导出序列开展下游分析	利用 FASTA、NEXUS 或 PHYLIP 文件进行单倍型网络、系统发育或功能验证设计。

11.1 参数设置建议

- 首次分析建议保持--cluster-threshold 默认值 0.15，并同时检查原始单倍型和聚类结果；
- Fisher 筛选适用于明确的两群体比较，不应代替完整的群体遗传统计分析；
- --plot-min-count 只用于改善图形可读性，不能作为删除低频单倍型的生物学依据；
- 表型关联结果应结合各类别样本量、群体结构和多重检验结果综合判断；
- PAV/SV 若需要恢复完整序列，应在 VCF 中保留序列解析的 REF/ALT 信息。

12 常见问题与处理方法

问题	处理方法
提示“Please provide --region or --region-file”	未提供分析区域。设置--region 或--region-file；图形界面中填写 Region 或选择区域文件。
提示分组文件不是 TAB 分隔	文件中使用了空格或逗号。请用制表符分隔，并确认文件无表头。
提示分组文件样本不在 VCF 中	样本名称不一致。检查大小写、前后空格及 VCF 表头中的样本名。
指定区域无变异	区域坐标、染色体名称或索引可能不匹配。核对 VCF、区域和 GFF3/GTF 中的 contig 名称。
Fisher 筛选后无位点	阈值过严或两个群体差异不足。检查群体名称、样本量、alpha 和校正方式。
没有生成基因结构图	未提供 GFF3/GTF，或注释文件中该区域没有可识别的 gene/exon/CDS/UTR 记录。
没有生成性状箱线图	未提供表型文件、性状列为非数值、样本名不匹配，或--trait-cols 指定了不存在的列。
VCF 读取速度慢	优先使用 bgzip 压缩并建立索引，安装 cyvcf2 或 pysam，避免在大型文件中使用 plain 后端。

问题	处理方法
Windows 程序无法启动	将软件完整解压到本地目录，避免路径过长或含特殊字符；必要时检查杀毒软件隔离记录。
输出图类别过多	提高--plot-min-count，使用--plot-hap-level cluster，或调整--cluster-threshold。
多倍体结果与预期不符	相位量和 GT 拷贝数，确认所用相位方法适合目标倍性和变异类型。
InDel 或 PAV 显示为+N/-N/PAV	这是紧凑状态编码。需要完整序列时，应确保 VCF 的 REF/ALT 包含可解析序列。

12.1 结果核查建议

- 先检查 ProcessedVariants.tsv，确认区域内位点及编码正确；
- 再检查 SampleGenotypeTokens.tsv，确认样本基因型状态与原始 VCF 一致；
- 检查 HapSummary.tsv 中的单倍型数量、样本列表和聚类编号；
- 检查 HapGroup.tsv 中的群体和表型是否正确对应；
- 最后结合图形和 TraitSignificance.tsv 解释群体差异与表型关联。

附录 A 参数速查表

参数	必需性	默认值	主要用途
--vcf	必需	无	指定相位 VCF/VCF.GZ/BCF。
--group	必需	无	指定样本分组文件。
--region / --region-file	二选一	无	指定单个或批量区域。
--outdir	必需	无	指定输出目录。
--mode	可选	inbred	选择单倍型重构模式。
--hetero-policy	可选	slash	设置 inbred 模式合。
--traits	可选	无	提供表型文件。
--trait-cols	可选	全部可用性状	指定需要分析的性状列。
--fisher-groups	可选	无	指定 Fisher 比的群。
--fisher-alpha	可选	无	设置 Fisher。
--fisher-adjust	可选	none	选择是否进行 BH 校正。

参数	必需性	默认值	主要用途
--cluster-threshold	可选	0.15	设置聚类距离阈值。
--vcf-backend	可选	auto	选择 VCF 取方式。
--plot	可选	关闭	用形出。
--gff	可选	无	提供基因注释文件。
--plot-format	可选	pdf	设置图形格式。
--plot-hap-level	可选	hap	选择原始或聚类层级绘图。
--plot-min-count	可选	1	设置绘图类别最小数量。

附录 B 输出文件速查表

类别	文件	用途
编码结果	*.AlleleStateMap.tsv	看原始字符的映射。
编码结果	*.ProcessedVariants.tsv	核位点和等位。
编码结果	*.SampleGenotypeTokens.tsv	核查每个样本的位点基因型。
单倍型结果	*.HapSummary.tsv	查看单倍型、聚类、材料和频数。
单倍型结果	*.HapGroup.tsv	接本、群、倍型和表型。
序列结果	*.Haplotype.fa	出非冗余倍型序列。
序列结果	*.Haplotype_sample.fa	导出样本或拷贝级序列。
序列结果	*.Haplotype.nex / *.Haplotype.phy	用于系统发育和网络分析。
统计结果	*.FisherFilter.tsv	查看 Fisher 位点筛选过程。
统计结果	*.TraitSignificance.tsv	查看性状总体和两两检验。
图形结果	*.HaplotypeHeatmap.*	查看单倍型变异状态。
图形结果	*.GeneHaplotype.*	查看基因结构与变异位置。
图形结果	*.GroupStackedBar.* / *.GroupPie.*	比较群体单倍型组成。
图形结果	*.TraitBoxplot.*	比较不同类别的表型分布。